Sopp-inator

Jenny L. Hopland, Marte Sævig og Nadia Lambrecht, 23.10.2026

1: BESKRIV PROBLEMET

OMFANG

Målet med prosjektet er å lage en nettside der brukeren beskriver en sopp ved hjelp av egenskaper som lukt, farge og form. En maskinlæringsmodell (ML) vurderer om soppen er giftig eller spiselig, og viser en sannsynlighet for resultatet. Hvis brukeren er usikker på en egenskap, kan hun velge «Vet ikke», og appen varsler dersom det ikke er nok informasjon til å gi en pålitelig vurdering. Løsningen er laget for nysgjerrige turgåere og læring, og skal ikke brukes til å avgjøre om en sopp er trygg å spise. Prosjektet undersøker også hvor få og enkle egenskaper en vanlig person må oppgi for at modellen skal kunne skille mellom giftige og spiselige sopper.

Giftinformasjonen anbefaler å lære om sopp gjennom kurs og oppdaterte soppbøker, og å gå soppen kontrollert av soppsakkyndige (Giftinformasjonen, 2026a, 2026b). Feltguiden som datasettet bygger på, understreker også at det ikke finnes noen enkel regel for å avgjøre om en sopp er spiselig (Mushroom, 1981). Vi testet derfor en enkel regel: «alle sopper med lukt er giftige». Den fanget opp 97,1% av de giftige soppene, men overså 23 giftige uten lukt. I tillegg ble 163 spiselige sopper feilaktig klassifiser som giftige. Det viser at enkle regler ikke er pålitelig nok, og at det blir mer komplisert å kombinere flere egenskaper manuelt.

ML passer derfor godt til prosjektet, siden datasettet inneholder 8124 merkede eksempler med 22 kategoriske egenskaper (Mushroom, 1981). En modell kan plukke opp kombinasjoner som enkle regler ikke får med seg, og den gir en sannsynlighet vi kan bruke til å si at noe er usikkert. Alle modellene vi utforsket oppnådde recall over 0,997 i CV, og den endelige modellen ga 0 false negatives og 0 false postives på testsettet, mot recall 0,971 og 163 falske alarmer for regelen.

Systemet består av tre deler: data og preprosessering (scr/prepare_data.py), en scikit-learn-pipeline som lagres som model.joblib, og en Streamlit-app som henter skjemaet fra features.json og kaller modellen. Hvis vi endrer kolonner og koder i dataene, må både modell og app oppdateres, så vi har blitt enige om felles filformat og kolonnenavn.

Siden produktet ikke er kommersielt, handler suksess først og fremst om læring og trygg bruk. Appen skal gi forståelige resultater, vise når modellen er usikker og tydelig informere om at den ikke kan brukes til å avgjøre om en sopp er trygg å spise. Vi er tre personer som deler data/metrikker, modellering og app/deployment. Det kreves lite datakraft, Google Colab og gratis hosting er tilstrekkelig for prosjektet.

METRIKKER

I prosjektet definerer vi giftige som den positive klassen. Den viktigste metrikken er recall for giftige sopper, som viser hvor stor andel av de giftige soppene modellen klarer å identifisere. Vi prioriterer denne fordi en false negative, der en giftig sopp klassifiseres som spiselig, kan få alvorlige konsekvenser. Derfor rapporterer vi både recall og de konkrete antallet slike feil. Vi måler også precision for giftige sopper og antall false positives, altså spiselige sopper som feil klassifiseres som giftige. Dette viser hvor ofte modellen gir falske alarmer. Accuracy rapporteres også, men er ikke hovedmetrikken fordi de ulike feiltypene har forskjellig alvorlighetsgrad. En modell som alltid velger den største klassen, oppgir omtrent 52% acccuracy, men en recall på 0 for giftige sopper.

Som software-metrikk måler vi latency, altså hvor lang tid appen bruker på å gi et svar. Målet er at brukeren skal få resultatet raskt, samtidig som usikkerhet vises tydelig. Dette gjør appen enklere å bruke og bidrar til at brukeren forstår når modellen ikke har nok informasjon til å gi en pålitelig vurdering.

Suksesskriteriene er at modellen oppnår minst 0,99 i recall for giftige sopper på testsettet, og enda bedre resultater enn regelen «odor !=n», som har en recall på 0,971 og 23 false negatives. Vi sikter også mot en precision på minst 0,95 og en responstid på under ett sekund. Selv 0 false negatives på testsettet betyr ikke 0 feil i virkeligheten, siden datasettet bare dekker 23 sopparter (Mushroom, 1981).

Siden produktet er en læringsdemo, handler suksesser om at brukeren forstår og klarer å bruke appen, ikke om lønnsomhet. Målet er at minst fire av fem testbrukere skal kunne fylle ut skjemaet uten hjelp, og at alle forstår at resultatet ikke kan brukes til å avgjøre om en sopp er trygg å spise. Etter publiseringen kan vi følge med på antall besøk og hvor ofte brukerne velger «Vet ikke». Dette kan gi oss en bedre forståelse av hvilke egenskaper som er vanskelig å vurdere, og hva som eventuelt bør forbedres i appen.

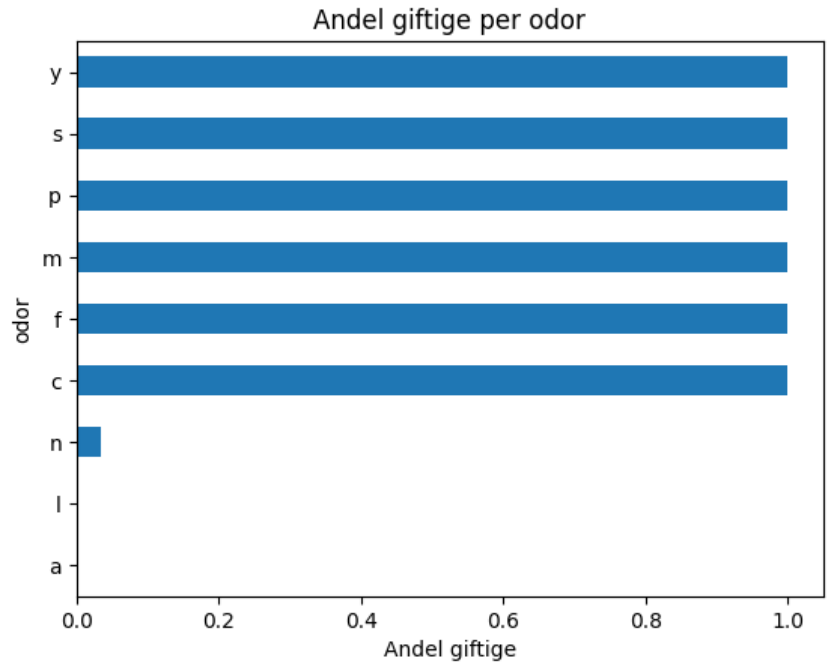
2: DATA

Prosjektet bruker UCI Mushroom-datasettet (dataset 73) fra UCI Machine Learning Repository (Mushroom, 1981). Dataene er tabelldata hvor hver rad beskriver én sopp med 22 kategoriske egenskaper, blant annet lukt, hattfarge og sporeavtrykksfarge. Verdiene er kodet med bokstaver, for eksempel «n» for ingen lukt. Datasettet er allerede smalet inn, og i har derfor ikke samlet inn data selv. Det lastes ned automatisk gjennom et script, slik at resultatene kan reproduseres.

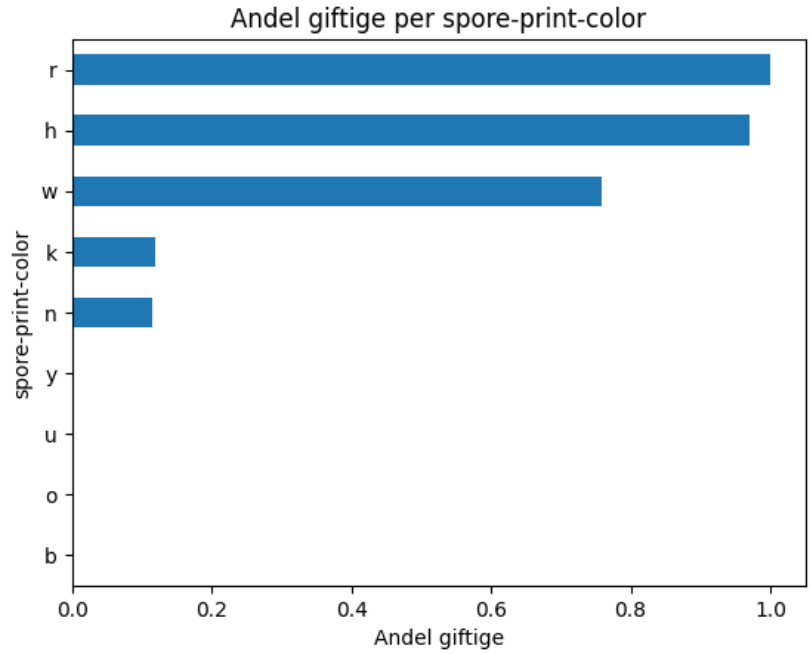
Problemet løses med supervised learning, der labelen viser om soppen er giftig eller spiselig. Labene følger datasettet og bygger på en feltguide for sopp fra Audubon Society. Hver art er klassifisert som spiselig, giftig eler av ukjent spiselighet, og sopp med ukjent spiselighet regnes som giftige (Mushroom, 1981). Dette gir en konservativ klassifisering, siden det er farligere å feilaktig klassifisere en giftig sopp som spiselig enn omvendt. Labelene kommer fra én kilde og er satt av eksperter, og dermed regner vi dem som konsistente, men vi har ikke mulighet til å kontrollere dem selv.

Datasettet inneholder 8124 sopper, hvor ca. 48% er klassifisert som giftige og ca. 52% som spiselige. Klassene er dermed relativt balanserte. Datamengden gir et godt grunnlag for å trene og teste modeller. En learning curve viser at modellen når full recall med ca. 1000 av de 6499 treningseksemplene, så datamengden er mer enn tilstrekkelig. Begrensingen ligger i hvor mange ulike arter dataene dekker, ikke i mengden data.

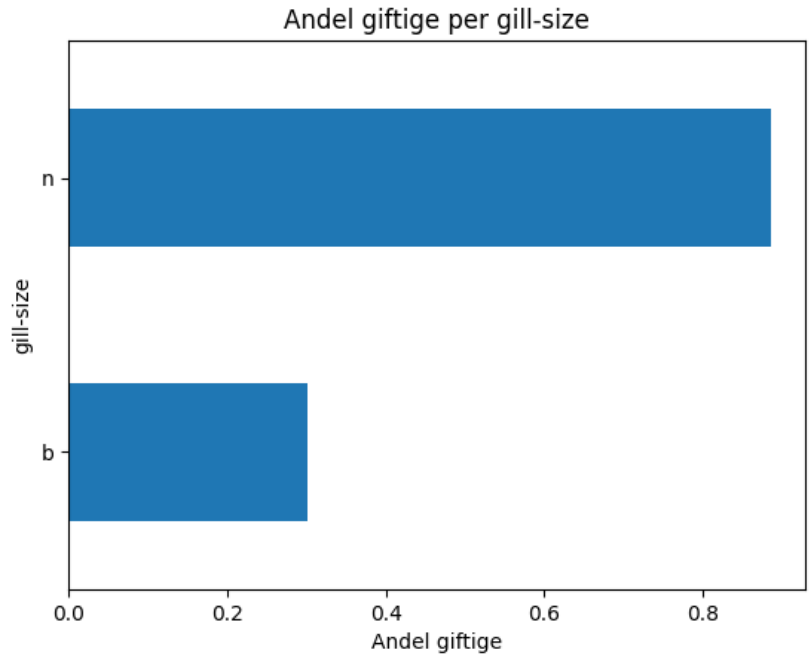
Figur 1 viser andelen giftige sopper for ulike lukttyper. Seks typer (fisk, krydret, stikkende, muggen, råtten og kreosot) består bare av giftige sopper, mens mandel og anis bare gir spiselige (Mushroom, 1981). Sopper uten lukt er stort sett spiselig, men rundt 3% er giftige. Lukt er dermed ikke nok til å avgjøre om en sopp er trygg å spise. Figur 2 og 3 viser at sporeavtrykksfarge og lamellstørrelse skiller klassene mindre tydelig. Omtrent 89% av soppene med smale lameller er giftige, sammenlignet med rundt 30% av dem med brede lameller. Dette tyder på at ingen enkelt egenskap er tilstrekkelig alene, og at det er relevant å undersøke hvordan flere egenskaper virker sammen.



Figur 1: Andel giftige sopper per lukttype.



Figur 2: Andel giftige sopper per sporeavtrykksfarge.



Figur 3: Andel giftige sopper per lamellstørrelse.

Datasettet inneholder ingen personopplysninger, så personvern er ikke et sentralt hensyn. De etiske utfordringene handler først og fremst om hvordan modellen brukes. Datasettet består av hypotetiske eksempler på 23 sopparter fra Agaricus- og Lepiota-familien (Mushroom, 1981). Modellen kan ikke vite om en sopp tilhører en art den ikke er trent på. Egenskapene i datasettet er hentet fra en feltguide, men brukere kan gjøre geil når de vurderer sopp i praksis. Hvis en giftig sopp blir klassifisert som spiselig, kan det få alvorlige konsekvenser. Giftinformasjonen fraråder derfor bruk av kunstig intelligens til å identifisere sopp som skal spises (Giftinformasjonen, 2026b). Appen er dermed kun ment som en læringsdemo og viser en tydelig advarsel mot å bruke modellen til å avgjøre om en sopp er trygg å spise.

Egenskapen stalk-root mangler verdier i 2480 rader, omtrent 30,5% av datasettet. I stedet for å fjerne disse radene erstattet vi de manglende verdiene med kategorien «unknown». På denne måten beholdes alle radene, og modellen kan lære om manglende informasjon har sammenheng med giftighet. Samme kategori brukes når brukeren velger «Vet ikke» i appen. Egenskapen veil-type ble fjernet fordi den bare har én verdi og dermed ikke bidrar med informasjon. Vi fant ingen duplikater i datasettet, så identiske rader kan ikke havne i både trenings- og testsettet. Etter rensingen står vi igjen med 21 egenskaper.

Alle egenskaper er kategorisk og må konverteres til tall før modellering. Dette gjøres med one-hot encoding som første steg i modellpipelinen. Skalering er ikke nødvendig, siden verdiene etter koding er 0 eller 1. Vi har ikke laget nye egenskaper, men undersøker i kap. 3 hvilke av de eksisterende egenskapene som er nødvendige. Datasettet er delt i 80% trening og 20% testing, med henholdsvis 6499 og 1625 rader. Delingen er stratifisert etter label og bruker en fast random_state, slik at alle i gruppen får samme oppdeling. Testsettet brukes kun til den endelige evalueringen.

3: MODELLERING

Som nevnt bruker vi giftig som den positive klassen og med recall som hovedmetrikken. Datasettet er stratifisert delt i et treningssett på 6499 rader og et testsett på 1625 rader. Modellvalg og tuning er gjort med 5-fold stratifisert kryssvalidering på treningsdata, mens testsettet brukes kun til endelig evaluering. One-hot encoding utføres i en scikit-learn-pipeline for å unngå datalekkasje.

Vi sammenligner to baselines. Modellen som alltid predikerer «spiselig», gir recall 0,00 og accuracy 0,518 på testsettet. Regelen «alle sopper med lukt er giftige» (odor != n) gir recall 0,971 (23 oversette giftige), precision 0,823 (163 falske alarmer) og accuracy 0,886. Denne regelen er den viktigste sammenligningen mot målene om minst 0,99 recall og 0,95 precision.

MODELLSAMMENLIGNING og TUNING

Vi sammenlignet logistisk regresjon, beslutningstrær (dybde 3 og ubegrenset), Random Forest og Gradient Boosting med 5-fold CV gjentatt tre ganger (15 målinger per modell, Tabell 1). Alle modellene oppnådde recall over 0,997, mot 0,971 for regelen. Random Forest overså ingen giftige sopper i noen av målingene (recall 1,000 ± 0,000). De øvrige modellene overså i gjennomsnitt 0,3–0,5 giftige sopper per fold, men forskjellene var små sammenlignet med standardavviket. Beslutningstreet med dybde 3 hadde lavest precision (0,973), noe som tyder på at det var for enkelt. Vi valgte Random Forest fordi modellen presterte best samlet og ble trent på under ett sekund.

	Modell	Recall (giftig)	Precision	Accuracy	FN per fold	Tid per fit (s)
0	Logistic Regression	0.9993 ± 0.0018	1.0000 ± 0.0000	0.9996 ± 0.0009	0.47	0.24
1	Decision Tree (depth=3)	0.9980 ± 0.0020	0.9733 ± 0.0052	0.9858 ± 0.0029	1.27	0.10
2	Decision Tree (ubegrenset)	0.9995 ± 0.0012	1.0000 ± 0.0000	0.9997 ± 0.0006	0.33	0.07
3	Random Forest	1.0000 ± 0.0000	1.0000 ± 0.0000	1.0000 ± 0.0000	0.00	0.61
4	Gradient Boosting	0.9994 ± 0.0012	1.0000 ± 0.0000	0.9997 ± 0.0006	0.40	0.97

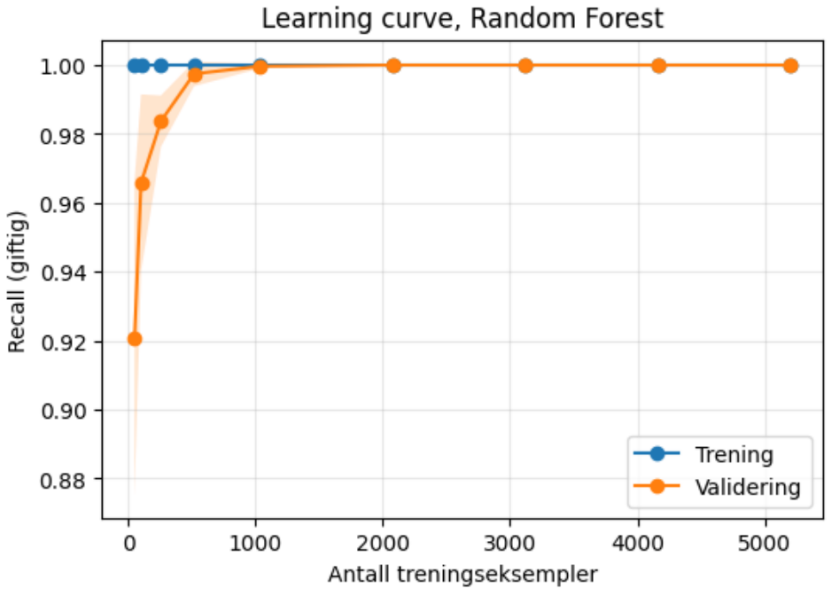
Tabell 1: Modellsammenligning

Grid search med 50, 100 og 200 trær og maksimal dybde på 3, 5 eller ubegrenset viste at dybden hadde størst betydning (Tabell 2). Dybde 3 og 5 ga recall på 0,93–0,98, mens ubegrenset dybde ga 1,000 uansett antall trær. Vi valgte derfor 50 trær uten dybdebegrensning, som ga full recall med færrest trær.

	n_estimators	max_depth	Recall (snitt)	Recall (std)	Accuracy (snitt)
0	50	None	1.000000	0.000000	1.000000
1	100	None	1.000000	0.000000	1.000000
2	200	None	1.000000	0.000000	1.000000
3	50	5	0.978939	0.007432	0.989845
4	100	5	0.978939	0.007432	0.989845
5	200	5	0.978939	0.007432	0.989845
6	100	3	0.968729	0.018608	0.984922
7	200	3	0.934579	0.027033	0.968459
8	50	3	0.925317	0.014502	0.963995

Tabell 2: Grid search for Random Forest

Learning curve viser hvordan modellens ytelse på data utvikler seg etter hvert som størrelsen på treningsdatasettet øker (Géron, 2019). Figur 4 viser at valideringsrecall øker fra ca. 0,92 ved 50 eksempler til 1,00 ved rundt 1000. Treningsrecall er 1,00 hele veien, og gapet mellom kurvene lukkes. Det tyder på at modellen ikke overtilpasses og trenger bare rundt 1000 av de 6499 treningseksemplene.

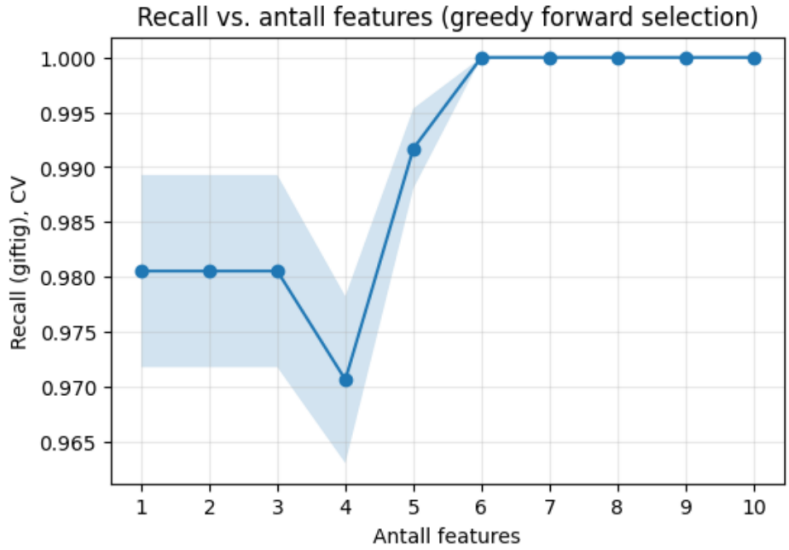


Figur 4: Learning curve for Random Forest

HVOR FÅ FEATURES TRENGS?

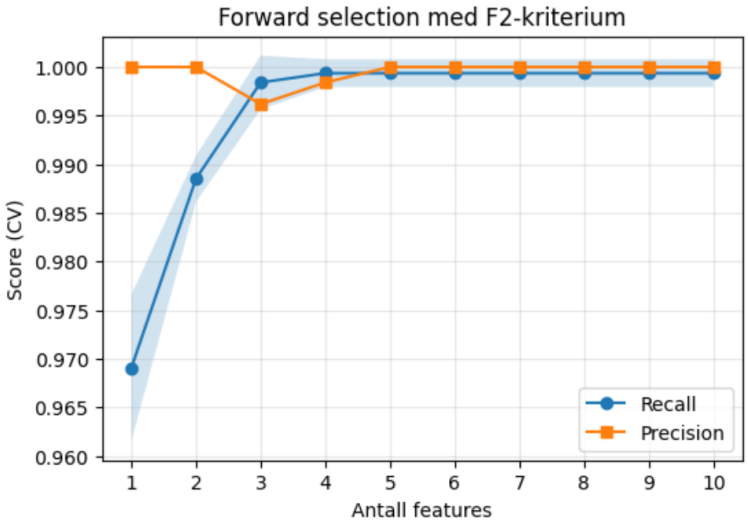
Vi undersøkte hvor få egenskaper en turgåer trenger å oppgi. Vi brukte greedy forward selection med et beslutningstre (dybde 6) og 5-fold CV. I hver runde la vi til egenskapen som ga best resultat. De utvalgte egenskapene ble deretter evaluert med Random Forest på testsettet, kun for å rapportere resultatene.

Med recall som utvalgskriterium nådde modellen 1,000 ved seks egenskaper (Figur 5). Resultatene for 1-3 egenskaper var likevel misvisende: accuracy var bare 0,54-0,56 og modellene ga 697-740 falske alarmer på testsettet fordi de klassifiserte nesten alle soppene som giftige. Recall alene er derfor ikke et godt utvalgskriterium, siden en modell som alltid predikerer «giftig» også får høy recall.



Figur 5: Forward selection med recall som kriterium

Vi gjentok søket med F2-score, som vektlegger recall, men også tar hensyn til precision (Figur 6). Da ble odor valgt først, etterfulgt av spore-print-color, stalk-surface-below-ring, cap-surface og gill-size. På testsettet (Tabell 3) overså modellen med bare odor 23 gifitge sopper (recall 0,971), som regelen i kapittel 1. Den ga ingen falske alarmer, trolig fordi den lærte at sopp med lukt av mandel eller anis er spiselige. Med tre egenskaper var det 3 falske negative, og med fem var det 2. Først med åtte egenskaper (odor, spore-print-color, stalk-surface-below-ring, cap-surface, gill-size, cap-shape, cap-color og bruises) oppnådde modellen samme resultat som med alle 21: ingen falske negative eller falske positive.



Figur 6: Forward selection med F2 som kriterium

	Modell	Recall (giftig)	Precision (giftig)	Accuracy	False negatives	False positives
0	Top 1: odor	0.971	1.000	0.986	23	0
1	Top 2: odor, spore-print-color	0.985	1.000	0.993	12	0
2	Top 3: odor, spore-print-color, stalk-surface-...	0.996	0.995	0.996	3	4
3	Top 4: odor, spore-print-color, stalk-surface-...	0.997	0.996	0.997	2	3
4	Top 5: odor, spore-print-color, stalk-surface-...	0.997	1.000	0.999	2	0
5	Top 8: odor, spore-print-color, stalk-surface-...	1.000	1.000	1.000	0	0
6	Alle 21 features	1.000	1.000	1.000	0	0

Tabell 3: Delsett av egenskaper evaluert på testsettet (F2-rekkefølge)

Få egenskaper gir nesten full ytelse, men ikke nødvendigvis et trygt resultat. Søket velger egenskaper ut fra informasjonsverdi, ikke hvor lett de er å observere og garanterer ikke det beste delsettet. CV-recall fra beslutningstreet (dybde 6) og testresultatene fra Random Forest er basert på ulike modeller og datagrunnlag.

ROBUSTHET: "VET IKKE" OG FEIL SVAR

Appen sender «vet ikke» som unknown, som modellen bare har sett i egenskapen stalk-root. Vi sammenlignet to Random Forest-modeller på 25% av treningsdataene: én trent på vanlige data og én trent på data der 20% og 40% av verdiene var erstattet med unknown. Valideringsdataene ble gradvis maskert, og resultatene er gjennomsnittet av 10 repetisjoner (Tabell 4). Uten maskering falt recall fra 0,985 ved 20% unknown til 0,755 ved 60% med henholdsvis ca. 12 og 192 oversette giftige sopper. Med maskering var recall 0,998 og 0,910. Maskering forbedrer resultatene, men løser ikke problemet når mange egenskaper er ukjente.

	Andel 'unknown'	Modell	Recall (giftig)	Accuracy	FN (snitt)
0	0 %	Uten maskering i trening	1.000	1.000	0.0
1	0 %	Med maskering i trening	1.000	1.000	0.0
2	10 %	Uten maskering i trening	0.996	0.998	3.0
3	10 %	Med maskering i trening	1.000	1.000	0.4
4	20 %	Uten maskering i trening	0.985	0.992	12.1
5	20 %	Med maskering i trening	0.998	0.999	1.4
6	40 %	Uten maskering i trening	0.915	0.955	66.9
7	40 %	Med maskering i trening	0.972	0.984	21.7
8	60 %	Uten maskering i trening	0.755	0.874	191.6
9	60 %	Med maskering i trening	0.910	0.946	70.3

Tabell 4: Robusthet mot "vet ikke"

Vi testet også feil svar ved å bytte ut verdier med tilfeldige verdier fra samme kolonne (Tabell 5). Ved 20% feil var recall 0,975 uten maskering og 0,983 med maskering, tilsvarende 20,1 og 13,1 oversette giftige sopper. Feil svar er dermed ni-ti ganger mer skadelig enn ukjente verdier. Derfor bruker appen den maskerte modellen og oppfordrer turgår til å velge «vet ikke» fremfor å gjette.

	Andel feil verdier	Modell	Recall (giftig)	Accuracy	FN (snitt)
0	0 %	Uten maskering i trening	1.000	1.000	0.0
1	0 %	Med maskering i trening	1.000	1.000	0.0
2	5 %	Uten maskering i trening	0.997	0.997	2.3
3	5 %	Med maskering i trening	0.999	0.998	0.8
4	10 %	Uten maskering i trening	0.991	0.991	6.8
5	10 %	Med maskering i trening	0.996	0.994	2.8
6	20 %	Uten maskering i trening	0.975	0.976	20.1
7	20 %	Med maskering i trening	0.983	0.977	13.1

Tabell 5: Robusthet mot feil svar

TERSKLER OG USIKKERHET

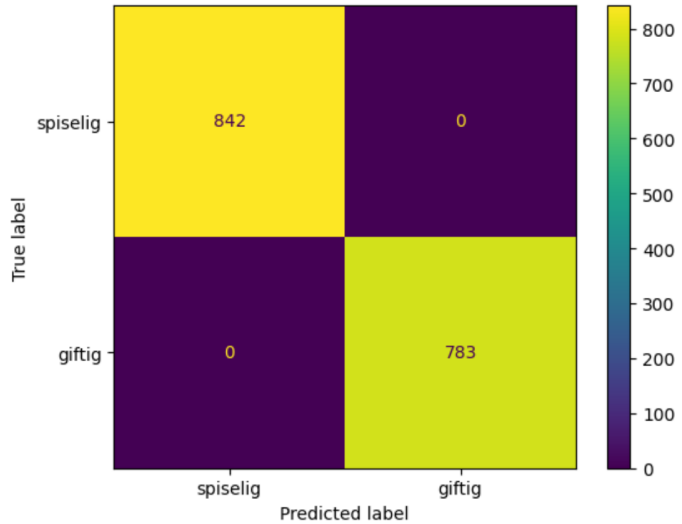
Modellen beregner sannsynligheten for at en sopp er giftig. Vi testet ulike terskler med out-of-fold-sannsynligheter fra treningsdata, med 0, 20 og 40% maskerte verdier. Lavere terskel gir høyere recall, men også flere falske alarmer (Tabell 6). Ved terskel 0,5 var recall 0,993, mens 0,05 ga recall 1,000, men 1585 falske alarmer. Siden det kan være livsfarlig å feilaktig erklære en giftig sopp trygg, valgte vi to terskler: ≤ 0,025 gir «ingen tegn på gift», ≥ 0,5 gir «sannsynlig giftig», og alt imellom gir «usikker, ikke spis». Ingen av de 9399 vurderingene av giftige sopper havnet i kategorien «ingen tegn på gift». Samtidig ble 22 % av de spiselige soppene klassifisert som usikre. Det godtar vi heller enn å risikere å anbefale en giftig sopp som trygg.

	Modell	Recall (giftig)	Precision (giftig)	Accuracy	False negatives	False positives
0	t=0.01	1.000	0.732	0.824	0	3434
1	t=0.05	1.000	0.856	0.919	0	1585
2	t=0.1	1.000	0.914	0.954	2	887
3	t=0.3	0.999	0.986	0.993	14	131
4	t=0.5	0.993	0.998	0.995	68	20
5	t=0.9	0.920	1.000	0.962	748	0
6	t=0.95	0.866	1.000	0.935	1262	0

Tabell 6: Terskler

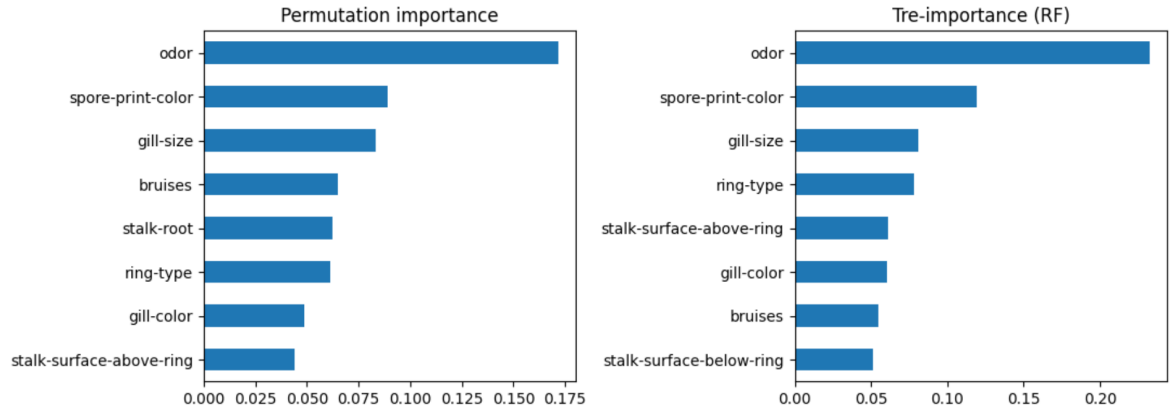
ENDELIG MODELL, FEILANALYSE OG IMPORTANCE

Den endelige modellen (Random Forest med 50 trær, trent med maskerte kopier) ble evaluert på testsettet med 1625 sopper, som ikke er brukt under modellvalg eller tuning. Forvirringsmatrisen (Figur 7) viser at alle 842 spiselige sopper ble klassifisert som spiselige, og at alle 783 giftige sopper ble klassifisert som giftige. Modellen hadde dermed ingen falske negative og ingen falske positive og gir recall, precision og accuracy på 1,00. Resultatet gjelder bare rene testdata uten manglende eller feil svar, og betyr ikke at modellen er feilfri i praksis.



Figur 7: Forvirringsmatrise på testsettet

Både permutation importance (målt med log loss, siden recall og accuracy nesten alltid er 1,0) og tre-importance rangerer odor høyest, etterfulgt av spore-print-color og gill-size (Figur 8). Dette stemmer med F2-søket. Feilanalysen viser også at modellen blir usikker når både odor og spore-print-color mangler. Appen bør derfor spørre om disse først, selv om sporeavtrykk kan være vanskelig å ta for en turgåer.



Figur 8: Permutation og Tre-importance

Selv om modellen ikke gjorde noen farlige feil på testsettet, betyr ikke det at den er feilfri i praksis. Datasettet dekker 23 arter fra to slekter og bygger på beskrivelser fra en feltguide. I virkeligheten vil brukere trolig hoppe over de vanskeligste egenskapene i stedet for å velge ukjente verdier tilfeldig. Appen er derfor en læringsdemo, ikke et sikkerhetsverktøy.

4: DEPLOYMENT

Appen er bygget med Streamlit og deployed på Streamlit community cloud (https://dat158mlsopp-group10.streamlit.app/) og koblet direkte til GitHub repository. Streamlit passet til prosjektet da det var behov en interaktiv web-app og simpelt ux-design uten store krav for html, css og js.

Det er brukt Python 3.12 til implementering ettersom Scikit-Learn ikke støtter Python 3.14. Applikasjonen er testet på Windows 11 og gruppemedlemmenes IOS enheter, og fungerer som forventet. Skjemaet (utklipp i Figur 9) er generert fra features.json, slik at app og model bruker samme liste over trekk. Hver rullegardinmeny viser enkle beskrivelser og en "hjelpe" tekst istedenfor datasett koder, slik at bruker kan forstå hva de trykker på.

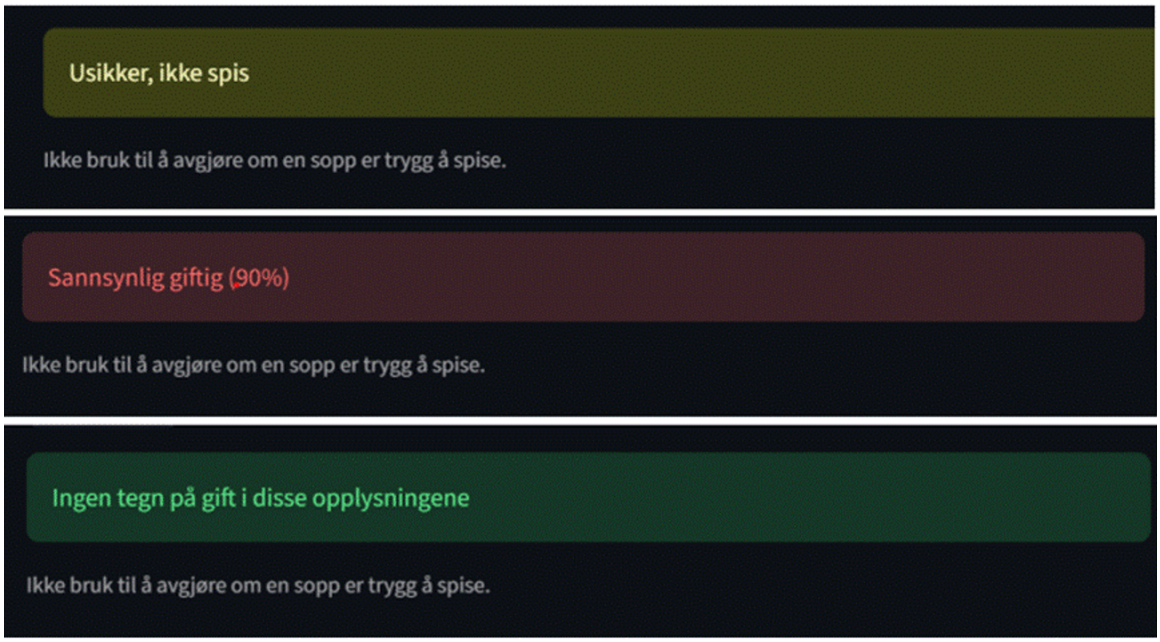


Figur 9: Skjema fra applikasjon

Skjemaet i applikasjonen har 3 utfall (Figur 10), basert på terskler fra config.json:

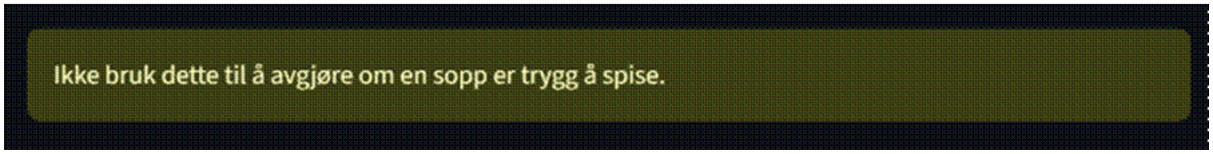
- Sannsynlighet >= 0.5 "Sannsynlig giftig"
- Sannsynlighet <= 0.025 "Ingen tegn på gift I disse opplysningene"
- Sannsynlighet > 0.025 & < 0.5 "Usikker, ikke spis"

Den lave terskel er bevisst streng ettersom en falsk negativ (giftig sopp kategorisert trygg) er mer risikabelt enn falsk alarm.



Figur 10: Utfall fra skjema i applikasjon

En advarsel står på toppen og bunnen av siden (Figur 11) om å ikke bruke modellen til å avgjøre om en sopp er trygg til å spise.



Figur 11: Advarsel fra skjema i applikasjon

Det er laget 5 pytest testere test/test_model.py. Disse tester at modellen returnerer forventet sannsynlighet, at input med alle trekk satt til "unknown" ikke krasjer, at kolonner I features.json matcher data, at features.json har samme struktur appen forventer og at terskel verdier (0 <= T_LOW < T_HIGH <= 1) er valide.

PREDIKASJONER

Appen er en læringsdemo og skal ikke brukes til å vurdere om en sopp er spiselig. En bruker skal kunne fylle inn fysiske trekk som observeres og få tilbake en av tre tilbakemeldinger. «Sannsynlig giftig» og «Usikker» betyr soppen ikke skal spises da den sannsynligvis er giftig. «Sannsynligvis ikke giftig» betyr modellen ikke har funnet tegn på gift i brukers oppgitte opplysninger. Resultatet er basert på 23 arter fra to slekter. Andre sopparter utenfor datasettet ligger utenfor det modellen har lært.

MONITORERING OG VEDLIKEHOLD

Monitorering er planlagt, men ikke implementert. I en reel drift ville input og resultat blitt logget, uten personopplysninger. Disse opplysningene ville gitt oversikt over input-kombinasjoner som ikke eksisterer i treningsdata, andel «vet ikke» svar. Endringer kan tyde på data drift eller at brukere vurderer arter som modellen ikke har kjennskap til.

Statisk trening er brukt. Datasettet er en fast samling beskrivelser som ikke endrer seg, og brukerinput har ingen bekreftende merkelapper, hvilket ville gjort dynamisk trening utrygt. Ved nye verifiserte data kan modellen gjenopptrenes med python src/train.py, evalueres på testsettet og implementeres på nytt. Versjonene er detaljert i requirements.txt for at modellen skal fungere som i appen.

Streamlit Community Cloud er gratis, og appen kan gå i dvale når den er ubrukt. Gratisversjonen har ingen innebygd logging, som gjør at monitorering ville måtte innebygges i applikasjonen. Dersom andel «Vet ikke» input eller ukjente kombinasjoner øker, vil en utvidelse av datagrunnlaget og gjenopptrening av modellen vurderes. For vedlikehold må Python 3.12 og Scikit-learn 1.6.1 holdes lik i trening og applikasjon ettersom model.joblib er trent med denne versjonen.

FORBEDRINGER

Viktige forbedringer for applikasjonen vil være flere arter, spesielt norske, slik at applikasjonen dekker et større mangfold. For å forbedre brukeropplevelse vil en illustrasjon av anatomi i en sopp, som endrer egenskaper etter brukers input kan gjøre det enklere å svare riktig ettersom bruker kan sammenligne i sanntid. For forbedring av sikkerhet bør applikasjonen foreslå en soppart basert på opplysninger fra bruker, og advare spesielt dersom arten har en dødelig sopp som kan ligne.

5: REFERANSER

Géron, A. (2019). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems* (2. utg.). O'Reilly Media.

Giftinformasjonen. (2026a, 13. august). Soppkontroll. Helsenorge. Hentet 10. oktober 2026 fra https://www.helsenorge.no/giftinformasjon/sopp/soppkontroll/

Giftinformasjonen. (2026b, 27. april). Unngå forgiftning med sopp. Helsenorge. Hentet 10. oktober 2026 fra https://www.helsenorge.no/giftinformasjon/sopp/unnga-soppforgiftning/

Mushroom [Datasett]. (1981). UCI Machine Learning Repository. https://doi.org/10.24432/C5959T